

Cheat Sheet: Correlación y Regresión Lineal

Probabilidad y Estadística — Regresión (IB)

Correlación $\neq$ causalidad Una correlación **no implica** causa-efecto; solo indica que, en promedio, cuando una variable aumenta, la otra tiende a aumentar (correlación positiva) o a disminuir (correlación negativa).

Variables y ejes

- x : variable **independiente** (predictora), se representa a lo largo del **eje horizontal**.
- y : variable **dependiente** (respuesta), se representa a lo largo del **eje vertical**.
- La variable que intentas **predecir** es la **dependiente** (y), y la variable que usas para predecir es la **independiente** (x).

Coefficiente de correlación (Pearson) r

- r es un valor entre -1 y 1 que indica **fuerza** y **dirección** de la relación lineal.
- El coeficiente producto-momento cumple: $-1 \leq r \leq 1$.
- Interpretación:
 - $r = 1$: correlación lineal positiva perfecta.
 - $r = -1$: correlación lineal negativa perfecta.
 - $r = 0$: **no** hay correlación lineal.

Recta de regresión (línea de mejor ajuste) Sabemos que la recta de mejor ajuste para predecir y a partir de x tiene forma

$$\hat{y} = mx + b,$$

donde:

- m es la **pendiente**,
- b es la **intersección con el eje y** (intercepto).

La calculadora suele dar directamente los valores de m y b .

Pendiente

$$m = \frac{\Delta y}{\Delta x}.$$

(La pendiente mide cuánto cambia y por cada unidad que cambia x).

Idea clave del ajuste por mínimos cuadrados La recta de mejor ajuste (regresión de y sobre x) minimiza la **distancia vertical** (residuos en y) de cada punto a la recta. Por eso, esa recta es la mejor cuando quieres predecir y .

Predicción e interpolación Para predecir/interpolarse un valor de y usando x , se sustituye el valor de x en $\hat{y} = mx + b$ y se calcula $\hat{y}$. Esto es coherente porque y es la variable **dependiente** y x la **independiente** en esa regresión.

Predecir x a partir de y Es tentador tomar $\hat{y} = mx + b$, sustituir y y despejar x , pero **no siempre es confiable** porque esa recta fue ajustada para minimizar errores **verticales** (en y), no **horizontales** (en x). Si deseas predecir x desde y , debes usar la regresión de x sobre y :

$$\hat{x} = c + dy,$$

donde d es la pendiente en este sentido y c el intercepto.

Regla de oro

La variable que quieres estimar va del lado izquierdo.

Si quieres estimar y , usa $\hat{y} = mx + b$. Si quieres estimar x , usa $\hat{x} = c + dy$.

Recordatorio (para hallar $\hat{x} = c + dy$):

1. Confirma que tenga sentido que x dependa de y (según el contexto).
2. En la calculadora, usa la misma función de regresión, pero **intercambia** los datos (ingresa y donde normalmente iría x , e ingresa x donde normalmente iría y).
3. Intercambiar variables **no cambia** el valor de r .

Redondeo Puedes escribir la ecuación con valores redondeados, pero para calcular predicciones usa los **valores exactos** que tiene la calculadora y redondea **al final**.

¿Cuándo usar $\hat{y} = mx + b$ y cuándo usar $\hat{x} = c + dy$? (Tabla rápida)

Lo que te piden	Ecuación correcta	Qué haces en la calculadora / sustitución
“Predice y dado x ” (por ejemplo: calificación y con horas de estudio x)	$\hat{y} = mx + b$ (regresión y on x)	Ajusta la regresión con x como lista X y y como lista Y. Sustituye el x dado y calcula $\hat{y}$.
“Predice x dado y ” (por ejemplo: horas x para lograr calificación y)	$\hat{x} = c + dy$ (regresión x on y)	Ingresa al revés: mete los valores de y como si fueran X, y los de x como si fueran Y. La ecuación que salga la interpretas como $\hat{x} = c + dy$. Sustituye el y dado y calcula $\hat{x}$.
“Solo despeja” (problema algebraico, no de predicción)	Despeje de la ecuación que te den	Puedes despejar, pero eso no convierte la recta en la regresión correcta del otro sentido.
Interpolación (valor dentro del rango de datos)	La que corresponda a lo que predices	Interpolación es usar un valor dentro del rango; aun así, usa la ecuación del sentido correcto (lo que predices a la izquierda).
Extrapolación (valor fuera del rango)	La que corresponda, pero con cuidado	Se puede calcular, pero es menos confiable. Menciona el riesgo si te lo piden.

Checklist express para elegir rápido

1. **¿Qué te están pidiendo encontrar?** Esa es la variable dependiente (va a la izquierda).
2. Si estás encontrando $y \Rightarrow$ usa y **sobre** x : $\hat{y} = mx + b$ (residuos verticales).
3. Si estás encontrando $x \Rightarrow$ usa x **sobre** y : $\hat{x} = c + dy$ (residuos horizontales).
4. **No uses “despejar” como sustituto** de la regresión del otro sentido (salvo $r = \pm 1$).